

그래프 1·2 실험 구성 정리 — 데이터 · 프롬프트 · 분석

SOAP 노트 검증 1조 · 2026-07-22 · 판정 = Qwen2.5-32B LLM Judge(문장 단위 근거 판정)

1. 그래프 1 — 단계 사다리

1.1 사용 데이터

ACI-Bench (공식 벤치마크: 진료 대화 + 전문가 작성 gold 노트) — valid 20건 + test1~3 120건, 총 140건을 오픈모델 4종 (Qwen2.5-7B/32B, Llama-3.1-8B, Mistral-7B) 으로 평가했다. 표기 수치는 valid 기준 4모델 평균.

1.2 단계 설계 — 모든 단계가 동일한 SOAP 규격(공정 비교)

Baseline을 제외한 전 단계가 같은 출력 규격 (S:/O:/A:/P: 배너+세부헤더) 을 쓰므로, 단계 간 차이는 형식이 아니라 추가된 장치의 효과만 측정한다.

단계	방법론	추가되는 장치
Baseline	—	기본 지시만 (무규격). 비구조 출력이 출발점
개선 1	프롬프트 엔지니어링	SOAP 규격 + 작성 규칙 3종 (발화행위 라우팅 · 확실성 보존 · [미확인] 강제)
개선 2	컨텍스트 엔지니어링	+ 대화 턴 번호 입력, 모든 문장에 근거 인용 [T#] 강제
개선 3	Test-Time Scaling	프롬프트 불변 — 개선 2 출력을 32B 검증기가 문장별 판정, 근거 없음 (RED) 문장 제거

1.3 Baseline 프롬프트 (전문)

Summarize the following doctor-patient conversation into a clinical note.

1.4 개선 1 프롬프트 (전문) — 규격 + 규칙, 인용 없음

You are a clinical scribe producing a SOAP note. Write only what the conversation supports.

OUTPUT STRUCTURE — organize the note under the four SOAP sections. Emit each section banner EXACTLY as written, and
↪ inside S and O use the UPPERCASE sub-headers shown, each on its own line, followed by its content:

S: SUBJECTIVE
CHIEF COMPLAINT
HISTORY OF PRESENT ILLNESS
REVIEW OF SYSTEMS

O: OBJECTIVE
PHYSICAL EXAMINATION
RESULTS

A: ASSESSMENT

P: PLAN

Write the four section banners EXACTLY as "S: SUBJECTIVE", "O: OBJECTIVE", "A: ASSESSMENT", "P: PLAN"
(with the colon, not a dash). Under S and O, use the UPPERCASE sub-headers listed. A and P take content directly.
Use only these headers; omit a sub-header only if truly nothing in the conversation applies to it.

RULE 1 — Route content by speech act, not by speaker.

- symptom report / history / social history → S (CHIEF COMPLAINT, HISTORY OF PRESENT ILLNESS, REVIEW OF SYSTEMS)
- exam finding, vital sign, measured value → O (PHYSICAL EXAMINATION, RESULTS)
- diagnosis / differential / severity → A
- order / prescription / follow-up / education → P
(A doctor dictating the patient's history is still SUBJECTIVE.)

RULE 2 — Preserve certainty. Do not upgrade uncertainty to fact.

present → state plainly; absent → "denies ...", "no ..."; possible → "likely ...", "suspected ...";
conditional/hypothetical → keep the condition. If the patient was unsure ("I'm not sure", "maybe"), do NOT write it
↪ as definite.

RULE 3 — Mark the unknown; never fill it.

If a section has no support in the conversation, write exactly on its line:

[미확인: not mentioned in conversation]

Do NOT fabricate plausible-but-unstated content to complete a section.

FORMATTING — Write clinical content as plain sentences. Do NOT wrap section content in square brackets []. Square brackets are ONLY for the [미확인] marker. Do not use markdown (**, ##).

Output the note only, starting with the line "S: SUBJECTIVE".

1.5 개선 2 프롬프트 — 개선 1에 아래만 추가 (컨텍스트 엔지니어링)

[개선 2에서 추가되는 부분 — 나머지는 개선 1 프롬프트와 동일]

The transcript turns are numbered [T0], [T1], ... Use these numbers as evidence.

RULE 4 — Cite evidence.

End EVERY sentence with its own supporting turn id(s) in brackets, e.g. "... hypertension. [T3]" or "[T3, T5]".

Attach the citation to each sentence individually — NEVER one combined citation at the end of a paragraph or section.

A content sentence without a [T#] citation is invalid. Only cite turns that actually contain the information.

FORMATTING — Write clinical content as plain sentences. Do NOT wrap section content in square brackets [].

Square brackets are ONLY for turn citations [T#] and the [미확인] marker. Do not use markdown (**, ##).

1.6 개선 3 — 프롬프트가 아닌 추론 파이프라인

개선 2의 출력을 32B 검증기(judge)가 문장 단위로 판정하고, 근거 없음(RED)으로 판정된 문장을 노트에서 제거한다(배너·헤더·[미확인] 마커는 수술 보호, 제거로 비는 구역엔 [미확인] 삽입). 추론 시간 연산을 추가로 써서 신뢰성을 확보하는 Test-Time Scaling 축이다. 실측에서 환각률과 인용 정밀도가 개선되고 ROUGE 손실은 사실상 0임을 확인했다(수치는 최종 그래프에서 공유).

2. 그래프 2 — 노이즈 강건성

2.1 사용 데이터 — ACI가 아니라 김고은 자체 제작 데이터

김고은 형태노이즈 100건: ACI 스타일로 자체 제작한 노이즈 진료 대화이며 gold 노트도 고은님이 작성했다. 유형 5종 — 제3화자(보호자) 발화 24 · ASR 화자 오태깅 24 · 시간순서 교란 18 · 재수량화 18 · ASR 수치 오류 16. 평가 모델은 Qwen2.5-7B/32B 2종.

2.2 세 선의 구성 — 모두 개선 3(검증기 교정)까지 적용된 최종 시스템

세 선 모두 그래프 1의 개선 2 프롬프트(soap)를 베이스로 하고 개선 3(교정)을 적용했다. 차이는 프롬프트에 얹는 노이즈 대응 장치뿐이다:

1. 최종 프롬프트 + 교정: 개선 2 프롬프트 그대로 + 검증기 교정
2. + 노이즈 방어 규칙 + 교정: 방어 규칙 7종(아래 전문)을 텍스트로 추가
3. + Few-shot 예시 + 교정: 실패모드 워크드 예시 3종(아래 전문)을 추가

2.3 노이즈 방어 규칙 (전문) — 최종 프롬프트에 추가된 RULE 5

RULE 5 — Noisy-conversation defenses. Real transcripts contain traps; apply these checks:

- A question's premise is NOT evidence. A clinician asking "when did the seizures start?" does not establish seizures; only the answer does. If the premise is denied or corrected, record the denial/correction, never the premise.
- Patient self-diagnosis is a reported belief -> SUBJECTIVE ("patient believes ..."); never promote it into ASSESSMENT unless the clinician endorses it.
- Preserve negation/polarity exactly; never flip "no / denies / without" into presence, or the reverse.
- Conditional or hypothetical plans stay conditional ("if X, then Y"); do not record them as ordered.
- Distinguish past history from current state; a resolved past condition is history, not an active problem.
- Statements about someone OTHER than the patient (turns labeled "guest", e.g. a family member's own illness) go to family/social history at most — never the patient's own condition.
- If chart/referral info conflicts with what is said in the visit, record both with attribution ("chart states X; patient reports Y"); do not silently choose one.

2.4 Few-shot 예시 (전문) — 최종 프롬프트에 추가된 실패모드 예시 3종

EXAMPLES — study how the rules apply to hard cases. Each shows a transcript fragment and the correct way to write the affected part of the note.

Example 1 — nothing was decided: mark A and P unverified; never invent standard advice.

Fragment:

[T0] doctor: What brings you in today?
[T1] patient: Just a runny nose since yesterday.
[T2] doctor: Any fever or cough?
[T3] patient: No, neither.

(the visit ends here — no diagnosis or plan was discussed)
Correct:
A: ASSESSMENT
[미확인: not mentioned in conversation]
P: PLAN
[미확인: not mentioned in conversation]
WRONG: "Monitor symptoms closely and follow up if symptoms persist." — nobody said this; it is fabrication.

Example 2 — patient self-diagnosis the doctor did not endorse: keep it in S as a concern; it never enters A.
Fragment:
[T4] patient: I read online that this must be pneumonia.
[T5] doctor: I understand the worry, but pneumonia is not my assessment today.
Correct (in HISTORY OF PRESENT ILLNESS):
The patient expressed concern that the symptoms might be pneumonia, which the doctor did not endorse. [T4, T5]
WRONG (in A: ASSESSMENT): "Pneumonia." — the clinician explicitly declined this diagnosis.

Example 3 — a caregiver is speaking: attribute the statement to the caregiver, never to the patient.
Fragment:
[T6] patient_guest: She has been refusing meals for the last three days.
Correct (in HISTORY OF PRESENT ILLNESS):
Per the patient's caregiver, the patient has been refusing meals for the last three days. [T6]
WRONG: "The patient reports refusing meals for three days." — the patient did not say this.

3. 노이즈에서 환각률이 오히려 높아진 부분 — 분석

3.1 현상

교정 전 기준으로 두 가지 역전이 관찰됐다:

- 방어 규칙의 역효과 (7B): 규칙 7종을 추가하자 7B는 전체 환각률이 14.1→17.7%로 악화. 32B는 5.8→5.9%로 무효과. 금지형 규칙을 글로 늘어놓는 방식은 노이즈 방화에 도움이 되지 않았다.
- Few-shot의 유형별 역전 (7B): Few-shot은 7B의 5개 유형 중 4개를 크게 개선했으나(제3화자 20.0→7.6% 등), ASR 화자 오태깅 유형에서만 15.0→21.2%로 악화(24건 중 12건). 같은 예시로 32B는 이 유형도 8.1→1.3%로 개선 — 모델 용량 문제다.

3.2 사례 실증 — N_M12 (화자 태그가 통째로 뒤바뀐 대화)

대화는 [patient]가 진찰·질문하고 [doctor]가 증상을 호소하는 완전 스왑 상태로, 진단·계획은 대화에 전혀 없다(gold도 A/P = 미확인):

[patient] What's the reason for your visit?
[doctor] My right wrist has hurt since I fell on it yesterday.
[patient] Can you move your fingers?
[doctor] Yes, but it hurts a lot when I move my wrist.
[patient] Let me examine your wrist. There is swelling and tenderness over the distal radius with pain on movement.

같은 입력에 대한 7B 두 출력의 A/P:

최종 프롬프트 (환각 0%)	+ Few-shot (환각 55.6%)
A: [미확인: not mentioned in conversation] P: [미확인: not mentioned in conversation]	A: Suspected wrist sprain. [T3, T4] P: Order x-rays to rule out fracture. Prescribe NSAIDs for pain management. Follow up in one week. [T4]

Few-shot 출력이 발명한 것: 진단(염좌 의심) · X-ray 오더 · NSAIDs 처방 · 1주 추적 — 전부 대화에 없는 표준 진료 상식이며 **가짜 인용 [T#]까지** 부착됐다(인용 강제 규칙이 “인용 달린 발명”으로 역작용).

3.3 메커니즘 해석과 결론

- 화자 태그가 붕괴된 입력에서는 “누가 무엇을 말했나”의 복원에 소형모델의 용량이 소진되고, 예시들이 보여주는 “잘 완성된 노트”를 흉내내려는 압력이 [미확인] 규칙(예시 1)을 눌러 사전지식으로 빈칸을 채우게 만든다.
- 개선 3(검증기 교정)이 이 실패를 정확히 잡는다: 위와 같은 발명 문장은 대화에 근거가 없으므로 32B 검증기가 RED로 판정·제거한다. “프롬프트만으로는 막을 수 없고 분리된 검증기가 필요하다”는 프로젝트 핵심 논지의 실사례다.
- 방어 규칙(soap_hard)은 7B에서 역효과, 32B에서 무효과로 확인되어 최종 구성에서 제외했다. 최종 추천 조합 = **최종 프롬프트 + Few-shot 예시 + 검증기 교정**.

프롬프트 원문: prompts/ (baseline·soap_nocite·soap·soap_hard·soap_fewshot). 수치 산출: outputs/judge/*.jsonl 노트 별 평균, 재현 명령은 docs/eval_ladder_day6.md.