

노이즈 강건성 평가 결과

자체 노이즈 데이터 2종 × 프롬프트 4단계 (7/20)

인공지능 커리어패스 1조 · 파이프라인/평가 파트 (송윤) · 데이터: 고은 · 다연

두 분이 만든 노이즈 데이터를 ACI 본평가와 동일한 파이프라인(생성 → 문장별 검증 AI 판정)에 넣은 결과입니다.

한 장 요약

무엇을 했나

고은 노이즈 100건(보호자 대리진술·화자 오태깅·시간 뒤섞임·수치 정정·ASR 숫자손상)과 다연 의미 함정 64쌍(같은 진료의 깨끗한 대화 vs 함정 삽입 대화)을 모델 2종(Qwen-7B/32B) × 프롬프트 4단계(기본→개선2→최종규격→노이즈강화)로 전부 돌렸습니다. 합계 생성 노트 1,824개, 검증 판정 약 4만 문장 + 함정 명제 검사 3,700회.

핵심 결과 4가지

- 1) 의미 함정(다연)은 거의 완벽 방어 — 보정 후 진짜 위반 64쌍 중 0~1건. 정정 발화가 있으면 모델이 알아듣습니다. 판별력은 v2(정정 없는 함정)에서 나올 것.
- 2) 형태 노이즈(고은)가 진짜 시험대 — 7B는 환각 13~18%로 폭증(ACI의 4~6배), 32B는 4~6%로 선방. 모델 크기가 강건성을 지배.
- 3) 새 발견: SOAP 규격의 부작용 — ”구역을 채워야 한다”는 압력이 짧은 대화에서 A/P 표준문구 날조를 유발(32B 4.2%→5.8%). 다음 프롬프트 수정 타깃.
- 4) 노이즈강화 프롬프트(soap_hard)는 역효과 — 7B에서 최악(17.7%). 규칙 추가는 답이 아님.

용어 2개만

환각률(HR) = 검증 AI(32B judge)가 ”대화에 근거 없음”으로 판정한 문장 비율.
함정 위반율(FCR) = 심어둔 금지 명제(예: ”환자가 폐렴 진단을 받았다”)를 노트에 받아쓴 사례 비율 — 노트 전체에 대해 ”이 주장을 담고 있나?”를 별도로 검사.

결과 ① — 다연: 의미 함정 64쌍 (clean vs noisy)

같은 진료의 깨끗한 버전과 함정 버전을 짝지어 비교 — 차이는 전부 ”함정 때문”이라고 말할 수 있는 설계.

모델	프롬프트	진짜 함정 위반	환각률 clean→noisy	내용 훼손(R1)
Qwen-7B	기본	1/64	5.7%→6.7%	없음
Qwen-7B	개선2	0/64	3.6%→3.6%	없음
Qwen-7B	최종규격	0/64	2.1%→3.2%	없음
Qwen-7B	노이즈강화	1/64	5.0%→3.0%	없음
Qwen-32B	기본~강화 전부	0/64	함정에서 오히려 감소	없음

- 32B는 noisy에서 환각이 줄어듭니다(예: 최종규격 2.3%→1.1%) — 정정 발화가 모델을 더 조심스럽게 만드는 효과.
- v1 함정은 전부 ”잘못된 정보 + 명시적 정정” 구조인데, 모델이 정정을 잘 알아듣는다는 게 확인. 다연님이 이미 계획한 v2(정정 없는 함정·중간 삽입)가 다음 판별 시험대.

데이터 QA 발견 (다연님께) — clean 쌍 대조 실험 덕에 금지 명제 3건이 **과광의임**을 발견 (예: "The patient is not pregnant."는 원본 진료에서 정당하게 참). v2에서 개체 특정형으로 좁히면 해결. 이런 실험 설계(clean 대조)가 라벨 오류를 자동으로 걸러준 좋은 사례입니다.

결과 ② — 고은: 형태·구조 노이즈 100건

모델	프롬프트	환각률	내용 충실도(R1)
Qwen-7B	기본	16.0%	0.445
Qwen-7B	개선2	13.3%	0.520
Qwen-7B	최종규격	14.1%	0.504
Qwen-7B	노이즈강화	17.7% ⚠	0.504
Qwen-32B	기본	4.2%	0.460
Qwen-32B	개선2	4.1%	0.593
Qwen-32B	최종규격	5.8%	0.538
Qwen-32B	노이즈강화	5.9%	0.541

(참고: 같은 모델의 ACI 정상 대화 환각률 — 7B 3.0%, 32B 1.2%)

유형별 환각률 (최종규격, 7B / 32B): 제3화자 20.0/14.0% · 화자 오타깅 15.0/8.1% · 시간 뒤섞임 15.9/1.8% · 수치 정정 7.0/0.0% · ASR 숫자 10.1/0.9%

- **7B는 노이즈에서 무너집니다**(환각 4~6배). 32B는 수치 정정·ASR 숫자를 사실상 완벽 처리 — **실서비스라면 노이즈 강건성만으로도 32B 선택 근거**.
- 플래그된 문장을 뜯어보면 대부분 보호자 귀속 오류가 아니라 **A/P 표준문구 날조**("Monitor symptoms closely" 류)입니다. 짧은 대화 + "구역을 채우라"는 규격 압력의 합작 — 고은님이 gold의 A/P를 미확인 처리한 설계와 정확히 충돌하는 지점이라, **[미확인] 규칙이 아직 A/P에서 안 먹힌다는 실증**입니다.

결론과 다음 단계

- **노이즈 상황 추천 조합 = 32B × 개선2** (환각 4.1% · 충실도 0.593 · 함정 위반 0). 정상 상황 결론(32B × 최종규격)과 함께 상황별 이원 운용.
- **프롬프트 수정 1순위**: 최종규격의 A/P에 "대화에 계획 논의가 없으면 표준 권고 대신 [미확인]" 규칙 명시 → 고은 데이터로 재평가(효과가 가장 잘 드러나는 테스트베드).
- **soap_hard 폐기/재설계**: 규칙 추가는 소형모델에 역효과. few-shot 예시 방식 검토.
- 발표 스토리: 기본 성능(ACI) → **형태 노이즈 강건성(고은)** → **의미 함정 방어(다연)** → 검증기 신뢰성 (함정셋 90.6% + 사람 κ 라벨링 진행 중).

상세 수치·위반 사례 전체: docs/noise_eval_results.md · 원자료 outputs/noise_analysis/ · 7/20 기준 · 판정: Qwen2.5-32B judge(문장 4만 개, 파싱 실패 0)