

진료대화 → SOAP 노트 「검증 자동화」

파이프라인·평가 파트 진행사항 공유 (7/18)

인공지능 커리어패스 1조 · 송윤

5분이면 다 읽을 수 있게 썼습니다. 표는 훑어만 봐도 되고, **굵은 글씨**만 따라가면 결론이 잡힙니다.

지금까지 진행 흐름

7/16	데이터·전제 검증(계획서 주장 4건 실측 교정) → 파이프라인 구축 (생성→채점→검증→리포트 자동화, 로컬 GPU 4장에 모델 서빙)
7/17~18	최종 출력규격(S/O/A/P + 문장별 인용) 확정 · 한글 번역(구조 보존) · 웹 데모 (대화 입력 → 노트 생성 + 환각 문장 빨간 표시)
7/18	본평가 : 4개 모델 × 프롬프트 단계 × 진료 140건 전체 격자 + 검증 AI 함정 실험 + 채점 버그 수정·전수 감사 → 결과 문서화(GitHub PR #1)

한 장 요약

무엇을 했나

AI 4종(Qwen 7B/32B, Llama 8B, Mistral 7B)에게 진료 대화를 주고 SOAP 노트를 쓰게 한 뒤, **검증 AI(judge)**가 노트의 모든 문장을 대화와 대조해서 “근거 있는 말인가?”를 채점했습니다. 공개 데이터(ACI-Bench) **140개 진료 전체**(valid 20 + test 120)로 돌렸고, 검증 AI 자체도 믿을 수 있는지 “**함정 실험**”으로 시험했습니다.

핵심 결과 3가지


- 1) **최고 조합 확정** — Qwen-32B + 최종규격 프롬프트: **환각률 1.2%, 문장의 96%에 근거 인용 부착**.
- 2) **검증 AI 성적표** — 일부러 심은 오류 139개 중 **90.6% 검출**(지어낸 문장은 100%).
- 3) **프롬프트가 성능을 좌우** — 기본 → 개선 프롬프트만으로 환각이 절반으로. 반대로 “AI에게 스스로 재검토시키기”(2회 생성)는 **효과 없음** → 비용만 2배라 폐기.

팀에 요청 (회의 안건)

- ① 검증 AI vs 사람 일치도 실험 — 문장 라벨링 **1인당 약 1시간** 협조 필요 (아래 § 6).
- ② GitHub 초대(collaborator) 수락 + PR #1 리뷰. ③ 백엔드 개선 로드맵 채택 여부 논의.

먼저, 용어 4개만 (쉬운 버전)

환각	AI가 대화에 없는 내용을 지어내서 노트에 쓰는 것. 의료 기록에선 가장 위험한 오류.
인용 [T3]	“이 문장의 근거는 대화의 3번째 발화”라는 각주 . 노트 문장마다 붙여서 사람이 바로 확인할 수 있게 함.
judge(검증 AI)	노트를 문장 단위로 잘라 대화와 대조하고 “근거 있음/없음”을 판정하는 별도의 큰 모델(Qwen-32B). 우리 프로젝트의 본체 .
ROUGE	모범답안 노트와 겹치는 정도 (0~1). 높을수록 빠뜨린 내용이 적다는 뜻. 단, 환각은 못 잡음 (1일차에 실증) → 그래서 judge가 필요.



결과 ① — 어떤 AI가 가장 잘 쓰나 (test 120건)

최종규격 프롬프트(soap: 명시적 S/O/A/P + 문장마다 인용 강제) 기준:

모델	환각률 ↓	인용 부착률 ↑	인용 정확도 ↑	충실도(R1) ↑
Qwen-32B	1.2%	95.9%	98.9%	0.501
Qwen-7B	3.0%	89.4%	97.0%	0.504
Mistral-7B	3.3%	84.3%	97.0%	0.461
Llama-8B	2.6%	83.5%	97.5%	0.417 ⚠

환각률=judge가 “근거 없음”으로 판정한 문장 비율 · 인용 부착률=[T#]가 달린 문장 비율 · 인용 정확도=단 인용이 실제로 근거로 인정된 비율 · R1=ROUGE-1(모범답안과 겹침)

쉬운 해석:

- **1순위 = Qwen-32B**: 100문장 중 근거 없는 문장이 1개 남짓, 96%의 문장에 정확한 각주. (단, 검증 AI도 Qwen-32B라 “자기 채점” 우려가 있음 → § 6의 사람 대조 실험으로 해소 예정)
- GPU가 부족한 환경이면 **Qwen-7B**가 차선 (작은 모델 중 가장 균형).
- **Llama는 최종규격에 부적합**: 노트를 너무 짧게 써서 내용을 빠뜨림(환각이 아니라 누락 문제).
- 프롬프트 효과는 확실: 기본 프롬프트는 인용 0% · 환각 3.5~6.2% → 개선 프롬프트에서 환각 절반, 인용 80%+. **같은 모델도 프롬프트에 따라 판판이 됩니다.**

결과 ② — 그 검증 AI는 믿을 만한가? (함정 실험)

검증 AI가 채점을 잘한다는 걸 어떻게 증명할까요? **정답 노트에 일부러 오류를 심고, 잡아내는지** 봤습니다.

심은 오류 유형 (예시)	개수	검출률
지어낸 문장 삽입 (없던 “당뇨 병력” 추가)	40	100%
부위 · 방향 바꾸기 (왼쪽→오른쪽, 고혈압→저혈압)	29	96.6%
숫자 바꾸기 (혈압 120→160, 용량 2배)	35	91.4%
부정 뒤집기 (“통증 없음”→“통증 있음”)	35	74.3%
전체	139	90.6%

- **약점도 정직하게 찾았습니다**: “없음↔있음” 뒤집기, 특히 “No murmurs.” 같은 초짧은 진찰 소견과 “확실치 않다→확실하다” 류를 잘 놓침. → 검증 프롬프트에 **부정/확실성 대조 지시**를 추가하고 이 함정 실험을 다시 돌려 개선을 확인하는 게 다음 단계.

- 재미있는 발견: **사람 의사가 쓴 정답 노트도 9.1%**는 “**대화에 직접 근거 없음**” 판정을 받습니다(의사가 관행으로 채워 넣는 문구들). 즉 우리 AI의 환각률 1~3%는 **사람 기준선보다 낮은** 수준입니다.

결과를 믿어도 되는 이유 (품질 점검)

- **채점기 버그를 잡았습니다**: 문단 끝에 인용을 몰아 단 노트가 부당하게 감점되던 버그 발견·수정. 수정 전 수치는 전부 폐기하고 재채점 완료. (한때 32B 인용 정확도가 0.21로 나왔던 건 전부 이 버그 탓 — 수정 후 전 모델 0.96~0.99)
- **560개 노트 전수 검사**: 이상 출력은 6건(1.1%) — 반복 루프 1, 깨진 출력 1, 헤더 반복 4. 결론을 바꿀 수준은 아니며, 실서비스용 **출력 검증 장치**가 필요하다는 근거로 로드맵에 반영.
- **판정 28,631문장 무결**: 판정 실패·형식 오류 0건.

다음 단계 — 팀 협조가 필요한 것

검증 AI vs 사람 일치도 실험 (가장 중요, 1인당 ~1시간)

문장 100~200개를 두 명이 **각자** 읽고 “대화에 근거 있음/없음”만 표시 → (a) 사람끼리 얼마나 일치하나, (b) 검증 AI가 사람과 얼마나 일치하나(kappa)를 계산합니다. “우리 검증기는 사람과 $\kappa=??$ 수준으로 일치한다”가 발표의 마지막 퍼즐입니다. 도구는 준비돼 있어서(pipeline.interrater) 라벨만 해주시면 됩니다.

그 외 백엔드 로드맵(요약): ① 생성 출력 검증 장치(반복·깨진 출력 자동 차단) ② 검증 프롬프트 부정/확실성 강화 ③ 판정 속도 최적화(같은 대화 재사용 캐싱, 문장 단위 실시간 판정) ④ 포맷을 프롬프트가 아니라 **디코딩 규칙으로 강제**(문법 제약) ⑤ 소형 검증 모델 2단 구성으로 비용 절감. 상세는 docs/backend_roadmap.md.

저장소	github.com/mself8/soap-note-verification (PR #1에 전부 반영)
결과 상세	docs/eval_results_day3.md — 이 문서의 모든 수치 + 재현 명령
개선 제안	docs/backend_roadmap.md — 근거 논문 링크 포함
라이브 데모	웹 플레이그라운드: 대화 입력 → SOAP 생성 + 환각 문장 빨간 표시 (서버 8000)

데이터: ACI-Bench(합성 진료대화 140건, IRB 이슈 없음) · 생성: 로컬 vLLM(A6000×4) · 판정: Qwen2.5-32B · 7/18 기준