

프롬프트 개선 경과와 성능 결과

SOAP 노트 검증 1조 · 2026-07-22 · 평가: ACL-Bench valid 20건, 오픈모델 4종 (Qwen2.5-7B/32B·Llama-3.1-8B·Mistral-7B), 판정 = Qwen2.5-32B LLM Judge

1. 프롬프트 (파이프라인)를 어떻게 바꿨나

단계 사다리 — 각 단계가 실제로 바꾼 것:

- **Baseline**: “진료 대화를 SOAP 노트로 요약하라” 수준의 기본 지시만. 출력 구조 강제 없음.
- **개선 1 · 프롬프트 엔지니어링**: 작성 규칙 명문화 — 발화행위 기준 S/O/A/P 라우팅 (화자가 아니라 발화 내용으로 분류), 확실성 보존 (“maybe”를 확정으로 승격 금지), 근거 없는 항목은 지어내지 않기.
- **개선 2 · 컨텍스트 엔지니어링**: 대화 턴에 번호를 부여해 입력 ([T0], [T1], ...) 하고, **문장마다 근거 턴 인용 [T#]** 을 강제. 구역 구조가 정착되고 인용 기반 검증이 가능해짐 — 인용 정밀도 지표가 이 단계부터 존재하는 이유.
- **개선 3 · Test-Time Scaling (검증기 자동 교정)**: 프롬프트가 아니라 **추론 시간 파이프라인** 개선. 개선 2의 출력을 32B 검증기 (judge) 가 문장 단위로 판정하고, 근거 없음 (RED) 문장은 원 생성모델이 재작성 → **재판정을 통과한 문장만 유지** (실패 시 삭제). ※ 기존 개선 3 (모델 스스로 검증하는 자기검증 2패스) 은 환각률이 오히려 악화 (3.5→4.2%) 로 실측되어, “분리된 검증기가 잡아서 고친다” 는 방식으로 교체했다.

노이즈 대응 프롬프트 2종 (동일 실패모드에 대한 규칙 vs 예시 A/B):

- **노이즈 방어 규칙 (soap_hard)**: 방어 규칙 7종을 텍스트로 추가 — 질문의 전제는 증거 아님 · 자기진단은 S만 (의사 승인 없인 A 금지) · 부정 뒤집기 금지 · 조건부 계획은 조건 유지 · 과거/현재 구분 · 보호자 (제3화자) 발화를 환자 상태로 귀속 금지 · 차트 충돌 시 출처 병기.
- **Few-shot 예시 (soap_fewshot)**: 규칙 대신 **실패모드 3개를 워크드 예시** (대화 조각 → 잘못된 노트와 이유 → 올바른 노트) 로 시연 — ① 결정된 것이 없으면 A/P는 [미확인] (보일러플레이트 발명 금지) ② 의사가 승인 안 한 자기진단은 S에만 ③ 보호자 발화는 “보호자에 따르면” 으로 귀속.


2. 성능 결과 ① — 단계별로 전 지표 개선

지표 (4모델 평균)	Baseline	개선 1	개선 2	개선 3
ROUGE-1 F1 (gold 유사도) ↑	0.491	0.517	0.518	0.520
구역정렬 (S/O/A/P 구역별 R1 평균) ↑	0.18	0.34	0.38	0.38 (유지)
환각률 (근거 없는 문장 비율) ↓	5.4%	5.0%	3.5%	1.5%
인용 정밀도 ↑	—	—	0.976	0.987
근거율 (= 100 - 환각률) ↑	94.6%	95.0%	96.5%	98.5%

- 교정은 품질 (ROUGE) 을 깎지 않고 (오히려 +0.002) 환각만 제거 — 재작성 문장이 재판정을 통과해 살아남는 덕. 모델별 교정 후 환각률: Llama **0.26%** / 32B 1.42% / 7B 1.88% / Mistral 2.51%.
- 인용 정밀도는 인용 기능이 개선 2에서 도입되므로 그 이전 단계엔 정의되지 않음 (결측 아님).

단계별 근거율 향상 — 모든 문장이 대화에 근거하는가


ACL-Bench valid 20건 · 4개 오픈모델 · 개선3 = 개선2 출력에 32B 검증기 (judge) 자동교정 적용



프롬프트 단계별 성능 — 4개 지표 모두 개선

ACI-Bench valid 20건 · 4개 모델 평균(파랑) · 개별(회색) · 개선1=프롬프트 · 개선2=컨텍스트 · 개선3=TTS(김중기 자동교정)


— 4개 모델 평균
— 개별 모델



3. 성능 결과 ② — 노이즈 대화: 규칙 추가는 효과 없음, 예시 제시가 답

형태 노이즈 100건 (고은님 자체 제작: 제3화자 · ASR 화자 오태깅 · 시간순서 · 재수량화 · ASR 수치, 유형당 노트별 평균 환각률):

프롬프트 전략	Qwen2.5-32B	Qwen2.5-7B
기존 ACI 프롬프트 (soap)	5.8%	14.1%
+ 노이즈 방어 규칙 (soap_hard)	5.9% (효과 없음)	17.7% (악화)
+ Few-shot 예시 (soap_fewshot)	0.4% (제3화자 0%)	8.0%



추가 실험 (고은님 few-shot 18예시 전체 삽입, v2): 예시를 3개 → 18개로 늘리자 양 모델 모두 악화 (7B 노이즈 8.0 → 18.0%, 32B 0.43 → 1.89%, 32B ACI R1 0.546 → 0.495). 출력이 압축되며 인용 밀도가 줄고 A/P 발명이 재발 — 예시는 양보다 실패모드를 직격하는 소수 정예가 답. 후속으로 약점 유형 (ASR 화자 오태깅) 만 선별 삽입하는 v3 실험을 권고.

4. 지표 안내 (이전 공유 대비 달라진 점)

- BERTScore → 구역정렬로 교체:** BERTScore는 ROUGE와 같은 ‘유사도’ 계열 (중복) 이며 개선 1에서 정점을 찍는 반면, 구역정렬은 개선 2의 실제 기여 (SOAP 구조 정착: baseline은 O 구역이 0점) 를 드러냄.
- 근거율 추가:** 환각률의 보수 (100 - 환각률). “증가하는 그래프” 용 표현일 뿐 같은 지표.
- 환각률 · 인용은 종전과 동일하게 32B LLM Judge의 문장 단위 판정.** 개선 3 수치만 교정된 출력 기준.

재현: repo soap-note-verification, docs/eval_ladder_day6.md 참조 (명령어 포함). 그래프 원본: docs/figures/.